

RUL-Prognose mit Time-Series Foundation Models bei fehlerhaften Sensordaten

BSc Jan Moritz

FH-Burgenland, Eisenstadt, Österreich

KURZFASSUNG

Bei der datenbasierten Instandhaltung wird die verbleibende Nutzungsdauer einer Maschine, die Remaining Useful Life (RUL), aus Sensordaten geschätzt. Im Betrieb können diese Daten jedoch unvollständig oder durch Messfehler verändert sein. Erste Studien setzen Time-Series Foundation Models (TSFM) für die RUL-Prognose ein. In der bisherigen Literaturrecherche wurde kein direkter Vergleich gefunden, der ihre Prognosequalität gegenüber etablierten Modellen bei gleichen künstlich erzeugten Sensorfehlern untersucht und zugleich den Aufwand des Cloud-Betriebs erfasst.

Die geplante Arbeit vergleicht MOMENT-1-small mit einem Long Short-Term Memory (LSTM) und einem Temporal Convolutional Network (TCN). MOMENT wird als unveränderter Merkmalsextraktor mit einem trainierbaren Regressionskopf eingesetzt. Als Datengrundlage dient der mit Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) erzeugte Datensatz der National Aeronautics and Space Administration (NASA). Vorgesehen sind die Teilmengen FD001 und FD003. In die Testdaten werden fehlende Einzelwerte, Übertragungslücken, Sensorausfälle und Sensordrift eingebracht. Anschließend wird anhand von Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) und NASA-Score untersucht, wie sich die Prognosefehler im Vergleich zu den unveränderten Daten entwickeln. Messungen zu Latenz, Durchsatz, Ressourcenbedarf und Kosten ergänzen den Vergleich. Einzelheiten des Versuchsaufbaus werden anhand technischer Vorversuche festgelegt.

Die Ergebnisse sollen zeigen, ob MOMENT-1-small bei fehlerhaften Sensordaten Vorteile bietet und welcher Aufwand damit verbunden ist. Die Aussagen gelten nur für die untersuchten Modelle und Versuchsbedingungen.

1 EINLEITUNG UND PROBLEMHINTERGRUND

Im Zuge von Industrie 4.0 werden Maschinen und Produktionsanlagen zunehmend vernetzt. Sensoren erfassen laufend ihren Betriebszustand, während Cloud-Infrastrukturen die entstehenden Daten verarbeiten. Predictive Maintenance nutzt diese Daten, um Veränderungen früh zu erkennen und Wartungen besser zu planen. Dadurch können ungeplante Stillstände und Instandhaltungskosten reduziert werden (Zonta et al., 2020, S. 1–2, 7).

Ein Teil davon ist die Prognose der Remaining Useful Life (RUL). Sie beschreibt die geschätzte Zeit beziehungsweise Anzahl an Betriebszyklen, bis eine Maschine oder Komponente eine festgelegte Ausfallgrenze erreicht. RUL-Prognosen helfen somit bei der Entscheidung, wann eine Wartung notwendig ist (Hu et al., 2019, S. 2).

Für die datenbasierte RUL-Prognose werden unter anderem Long Short-Term Memory (LSTM), Gated Recurrent Units (GRU), Convolutional Neural Networks (CNN) und Temporal Convolutional Networks (TCN) eingesetzt. Diese Modelle erlernen anhand historischer Sensordaten zeitliche Zusammenhänge und Degradationsmuster, aus denen sie die verbleibende Nutzungsdauer ableiten (Wu et al., 2024, S. 15–16; Wang et al., 2020, S. 3, 6).

Ein verbreiteter Benchmark ist der mit Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) erzeugte Datensatz der National Aeronautics and Space Administration (NASA). Er enthält simulierte Sensordaten von Turbofan-Triebwerken, deren Trainingsverläufe bis zum Ausfall reichen. Die ursprünglichen Messreihen enthalten keine fehlenden Sensorwerte. In realen Anwendungen können dagegen Sensor- und Kommunikationsfehler einzelne Messwerte oder ganze Sensorkanäle ausfallen lassen. Auch systematische Messabweichungen und Sensordrift können auftreten. Solche Störungen können die RUL-Prognose verschlechtern und werden daher bereits durch gezielte Veränderungen der Benchmarkdaten untersucht (Tang, 2026, S. 7–10).

Neben den etablierten Modellen werden inzwischen Time-Series Foundation Models (TSFM) untersucht. Modelle wie MOMENT werden auf umfangreichen Zeitreihensammlungen aus unterschiedlichen Anwendungsbereichen vortrainiert. Die dabei erlernten Merkmale können anschließend für weitere Aufgaben verwendet werden (Goswami et al., 2024, S. 1–4). Dintén und Zorrilla nutzen die von MOMENT erzeugten Merkmale bereits für die RUL-Prognose auf C-MAPSS, untersuchen jedoch keine beschädigten Testdaten (Dintén & Zorrilla, 2025, S. 246, 252–255). El-Ghoussani et al. kombinieren wiederum Chronos-2 mit einem kleinen Regressionskopf und nennen die Robustheit bei fehlenden Sensoren als offene Forschungsfrage (El-Ghoussani et al., 2026, S. 2–4).

Die geplante Arbeit vergleicht deshalb MOMENT-1-small mit einem LSTM und einem TCN unter gezielt veränderten Testbedingungen. Bei MOMENT bleibt der vortrainierte Encoder unverändert, während ein zusätzlicher Regressionskopf für die RUL-Schätzung trainiert wird. Fehlende Messwerte, Übertragungslücken, Sensorausfälle und Drift sollen zeigen, wie empfindlich die Modelle auf eine nachlassende Datenqualität reagieren. Neben der Prognosegüte werden ihr Ressourcenbedarf und die Kosten des Cloud-Betriebs untersucht. Damit soll beurteilt werden, welchen Nutzen der gewählte TSFM-Ansatz gegenüber den beiden für diese Aufgabe trainierten Modellen bietet.

2 STAND DES WISSENS

Predictive Maintenance nutzt Zustandsdaten, um Wartungen besser zu planen. Dafür werden Verfahren benötigt, die den Zustand einer Maschine bewerten und ihre weitere Entwicklung vorhersagen. Auch der wirtschaftliche Nutzen der Wartungsentscheidung muss berücksichtigt werden (Vogl et al., 2016; Zonta et al., 2020; Verbert et al., 2017). Eine wichtige Prognosegröße ist die RUL. Sie kann mit physikalischen, datenbasierten oder hybriden Verfahren geschätzt werden. Neuere Übersichten zeigen, dass dafür zunehmend tiefe neuronale Netze eingesetzt werden. Probleme bestehen weiterhin bei der Datenqualität, der Vergleichbarkeit der Versuche und der Übertragung auf andere Anlagen (Hu et al., 2019; Berghout & Benbouzid, 2022; Wu et al., 2024; Amin et al., 2026).

C-MAPSS wird häufig als Benchmark für datenbasierte RUL-Verfahren verwendet. Der Datensatz enthält simulierte Verläufe von Turbofan-Triebwerken mit unterschiedlichen Betriebs- und Fehlerbedingungen (Saxena et al., n. d.). Ji et al. reduzieren die Zahl der Merkmale mit einer Hauptkomponentenanalyse und verarbeiten die Zeitreihen anschließend mit einem bidirektionalen LSTM (Ji et al., 2020). Li et al. verwenden stattdessen ein tiefes CNN, das zeitliche Fenster der Sensordaten verarbeitet (Li et al., 2018). Listou Ellefsen et al. kombinieren unüberwachtes Vortraining mit einer überwachten RUL-Schätzung. Dadurch kann das Modell auch mit weniger Verläufen trainiert werden, für die RUL-Werte vorliegen (Listou Ellefsen et al., 2019). Wang et al. verbinden einen Convolutional Autoencoder mit einem TCN und prüfen das Modell ebenfalls auf C-MAPSS (Wang et al., 2020, S. 6–10). Diese Arbeiten zeigen, dass sowohl rekurrente Modelle als auch temporale Faltungen für die RUL-Prognose geeignet sind. Bei der Auswertung werden jedoch meist vollständige Sensorkanäle verwendet.

TSFM werden auf großen Sammlungen unterschiedlicher Zeitreihen vortrainiert und können anschließend für neue Aufgaben verwendet werden. Chronos wandelt Messwerte in diskrete Tokens um und nutzt anschließend Sprachmodellarchitekturen für probabilistische Prognosen (Ansari et al., n. d.). Das Modell Time Series Foundation Model (TimesFM) teilt die Eingabe in Abschnitte und erzeugt mit einem Decoder Prognosen für zuvor unbekannte Datensätze (Das et al., 2024). MOMENT unterstützt Prognose, Imputation, Klassifikation und Anomalieerkennung. Eine RUL-Regression wird in der ursprünglichen Untersuchung jedoch nicht betrachtet (Goswami et al., 2024, S. 3–5). Dintén und Zorrilla verwenden MOMENT als unveränderten Merkmalsextraktor für C-MAPSS. Bei kleinen Trainingsmengen zeigen sich Vorteile für einzelne nachgeschaltete Modelle, jedoch nicht für alle untersuchten Verfahren. Fehlerhafte Sensordaten werden nicht untersucht (Dintén & Zorrilla, 2025, S. 246, 252–255). El-Ghoussani et al. verbinden Chronos-2 mit einem trainierbaren Regressionskopf und vergleichen den Ansatz mit LSTM, GRU und TCN. Längere Datenlücken werden vor der Auswertung entfernt. Wie robust das Modell gegenüber solchen Fehlern ist, bleibt daher offen (El-Ghoussani et al., 2026, S. 2–4).

Fehlende Werte in Zeitreihen werden auch unabhängig von der RUL-Prognose untersucht. Gated Recurrent Unit with Decay (GRU-D) berücksichtigt dafür Masken und die Zeit seit der letzten vorhandenen Beobachtung (Che et al., 2018). Bidirectional Recurrent Imputation for Time Series (BRITS) verarbeitet eine Zeitreihe vorwärts und rückwärts, um fehlende Werte aus früheren und späteren Beobachtungen zu schätzen (Cao et al., n. d.). Beide Verfahren wurden nicht für die RUL-Prognose auf C-MAPSS entwickelt. Zhang und Liu verbinden dagegen die Rekonstruktion fehlender Werte direkt mit der RUL-Schätzung in einem CNN-LSTM-Modell. Die Trainingsdaten werden bereits künstlich beschädigt, sodass das Modell die untersuchten Fehlermuster beim Training kennenlernt (Zhang &

Liu, 2023, S. 4–6, 9–14). Tang untersucht Datenverluste, Sensorausfälle, Messabweichungen und Drift. Ein generatives Modell rekonstruiert zuerst die Sensordaten, bevor ein weiteres Modell die RUL schätzt. Ein Vergleich mit einem TSFM fehlt (Tang, 2026, S. 3–6, 9–10, 19).

Neben der Prognosequalität ist der Rechenaufwand der Modelle relevant. Henderson et al. empfehlen, Rechenzeit, verwendete Hardware und Energiebedarf nachvollziehbar zu dokumentieren (Henderson et al., n.d.). Auch in den RUL-Studien werden solche Fragen teilweise aufgegriffen: Dintén und Zorrilla berichten Trainings- und Inferenzzeiten, während Tang den Aufwand seines Verfahrens zur RUL-Prognose unter Sensorfehlern untersucht (Dintén & Zorrilla, 2025, S. 255; Tang, 2026, S. 19). Wen und Chen vergleichen TSFM mit kleineren Modellen. In ihrem C-MAPSS-Versuch erzielt ein TCN-Autoencoder bessere Klassifikationsergebnisse als MOMENT und benötigt weniger Rechenzeit und belegt weniger Speicher auf der Graphics Processing Unit (GPU). Da Risikoklassen statt RUL-Werten vorhergesagt werden, lässt sich das Ergebnis nicht direkt auf die RUL-Regression übertragen (Wen & Chen, 2026, S. 2–5).

Die bisherigen Arbeiten zeigen, dass sowohl die RUL-Prognose mit TSFM als auch der Umgang mit fehlerhaften Sensordaten bereits untersucht werden. Einzelne Studien berücksichtigen dabei auch den Rechenaufwand. In der bisherigen Literaturrecherche wurde jedoch kein Vergleich gefunden, der MOMENT, LSTM und TCN für die RUL-Prognose mit denselben gezielt veränderten Testdaten untersucht und zugleich den Aufwand ihres Cloud-Betriebs erfasst. Offen bleibt damit, wie sich die Prognosequalität dieser Modellansätze bei zunehmenden Datenfehlern verändert und welcher Ressourcenbedarf damit verbunden ist. Die geplante Arbeit untersucht diesen Zusammenhang unter gemeinsamen Versuchsbedingungen. Ihr Beitrag liegt im Vergleich der Modelle, nicht in der Entwicklung eines neuen Prognosemodells.

3 WISSENSCHAFTLICHE FRAGESTELLUNG

Diese Arbeit untersucht, wie gut sich MOMENT-1-small für eine cloudbasierte RUL-Prognose mit fehlerhaften Sensordaten eignet. Als Vergleich dienen ein LSTM und ein TCN, die speziell für diese Aufgabe trainiert werden. Bewertet werden die Prognosequalität und der Aufwand für den Betrieb in der Cloud. Daraus ergibt sich folgende Forschungsfrage:

Wie unterscheiden sich MOMENT-1-small, ein LSTM und ein TCN bei der RUL-Prognose mit fehlerhaften C-MAPSS-Sensordaten hinsichtlich Prognosequalität, Robustheit, Inferenzlatenz, Ressourcenbedarf und Cloud-Kosten?

Zur Beantwortung der Forschungsfrage werden folgende Teilfragen untersucht:

1. Wie verändern sich die Prognosefehler der Modelle bei unterschiedlichen Arten und Stärken von Sensorfehlern?
2. Welche Unterschiede zeigen sich bei Inferenzlatenz, Durchsatz und Ressourcenbedarf unter vergleichbaren Betriebsbedingungen?
3. In welchem Verhältnis stehen die Kosten des Cloud-Betriebs zur erreichten Prognosequalität und Robustheit?

Für die Hauptuntersuchung ist C-MAPSS FD001 vorgesehen. FD003 soll den Vergleich ergänzen. Das Training für die RUL-Prognose erfolgt ohne zusätzlich erzeugte Sensorfehler. Erst die Testdaten werden verändert, um eine Verschlechterung der Datenqualität während des Betriebs nachzubilden. Die Modelle werden nicht nachträglich an diese Testfehler angepasst.

4 FORSCHUNGSMETHODIK

Zur Beantwortung der Forschungsfrage ist ein experimenteller Vergleich von MOMENT-1-small, LSTM und TCN vorgesehen. Zunächst wird untersucht, wie genau die Modelle die RUL bei unveränderten Sensordaten vorhersagen. Anschließend werden Fehler in die Testdaten eingebracht, um deren Einfluss auf die Prognosen zu bestimmen. Ergänzende Messungen in der Cloud sollen zeigen, welcher Rechenaufwand mit dem Einsatz der Modelle verbunden ist. Dieses Thesis Book beschreibt den geplanten Ablauf. Die konkreten Modelleinstellungen und Messbedingungen werden bei der Umsetzung anhand von Vorversuchen festgelegt, bevor die eigentliche Auswertung der Testdaten beginnt.

4.1 Datengrundlage und Aufbereitung

Als Datengrundlage dient C-MAPSS. Der Datensatz enthält simulierte Sensorverläufe von Turbofan-Triebwerken, deren Schädigung bis zu einer festgelegten Ausfallgrenze fortschreitet (Saxena et al., n. d., S. 1–2, 7). Für die Hauptuntersuchung ist FD001 vorgesehen. FD003 soll ergänzend verwendet werden, um den Vergleich auf einen weiteren Teildatensatz auszudehnen. Eine Untersuchung aller Betriebsbedingungen von C-MAPSS ist nicht geplant.

Die vorgegebene Aufteilung in Trainings- und Testtriebwerke bleibt erhalten. Ein Teil der Trainingstriebwerke wird zur Validierung verwendet. Erst danach werden die Zeitreihen in Eingabefenster zerlegt, damit Ausschnitte desselben Triebwerks nicht gleichzeitig im Trainings- und im Validierungsdatensatz vorkommen. Auch die Auswahl und Skalierung der Sensorwerte erfolgen ohne Informationen aus den Testdaten. Solche Trennungen sind wichtig, um eine Überschätzung der Modellleistung durch Data Leakage zu vermeiden (Kapoor & Narayanan, 2023, S. 4–5).

Alle Modelle sollen auf denselben Sensoren, Beobachtungszeiträumen und RUL-Zielwerten aufbauen. Die Fensterlänge und eine mögliche Begrenzung der RUL werden in den Vorversuchen festgelegt. Dabei muss die Zieldefinition für Training, Validierung und Auswertung zusammenpassen. Modellinterne Verarbeitungsschritte, etwa eine zusätzliche Normalisierung oder das Anpassen der Eingabelänge, werden getrennt berücksichtigt.

4.2 Modelle und Training

MOMENT-1-small soll als vortrainierter Merkmalsextraktor eingesetzt werden. Sein Encoder bleibt unverändert, während ein zusätzlicher Regressionskopf darauf trainiert wird, aus den erzeugten Merkmalen einen RUL-Wert abzuleiten. Ein ähnlicher Ansatz wurde bereits für die RUL-Prognose mit MOMENT untersucht (Dintén & Zorrilla, 2025, S. 246). Wie die einzelnen Sensorkanäle verarbeitet und ihre Merkmale zusammengeführt werden, wird zunächst in einem technischen Vorversuch geprüft. Als Vergleich dienen ein LSTM und ein TCN, die anhand der C-MAPSS-Trainingsdaten für die RUL-Prognose trainiert werden.

Die Modelleinstellungen werden mit den Validierungsdaten ausgewählt. Dafür ist eine begrenzte Hyperparametersuche vorgesehen. Als Verfahren bietet sich Random Search an, das gegenüber einer vollständigen Rastersuche bei gleichem Suchaufwand Vorteile haben kann (Bergstra et al., n. d., S. 281–283). Trainingsläufe werden mit unterschiedlichen Zufallsinitialisierungen wiederholt, da die Initialisierung und die Wahl der Hyperparameter das Ergebnis beeinflussen können (Bouthillier

et al., n. d.). Die Zahl der Wiederholungen richtet sich nach den Vorversuchen und dem verfügbaren Rechenbudget.

Für das Training zur RUL-Prognose werden keine zusätzlichen Sensorfehler erzeugt. Davon zu unterscheiden ist das bereits abgeschlossene Vortraining von MOMENT, bei dem unter anderem maskierte Zeitreihen zur Rekonstruktion verwendet wurden (Goswami et al., 2024, S. 3–4). Eine erneute Anpassung der Modelle an die später untersuchten Testfehler ist nicht vorgesehen.

4.3 Fehlerexperimente

Untersucht werden sollen zufällig fehlende Einzelwerte, zusammenhängende Übertragungslücken, Ausfälle einzelner Sensoren und Sensordrift. Jede Fehlerart wird zunächst einzeln betrachtet und in mehreren Stärken erzeugt. Die konkreten Anteile fehlender Werte, Ausfalldauern und Driftstärken werden vor den Hauptversuchen festgelegt.

Die Fehler werden in die Testverläufe eingebracht, bevor daraus die Eingabefenster entstehen. So bleibt ein Messwert auch in überlappenden Fenstern auf dieselbe Weise verändert. Alle Modelle erhalten jeweils dieselben fehlerhaften Daten. Die tatsächliche RUL wird durch diese Änderungen der Messwerte nicht verändert.

Damit die Modelle trotz fehlender Werte eine Prognose erzeugen können, ist eine einfache Ergänzung der Daten vorgesehen. Dafür kommt beispielsweise die Übernahme des letzten gültigen Sensorwerts infrage. Es dürfen keine Messwerte verwendet werden, die zum Prognosezeitpunkt noch nicht vorliegen. Der Schwerpunkt liegt auf dem Verhalten der Modelle nach einer einheitlichen Fehlerbehandlung und nicht auf der Entwicklung eines neuen Rekonstruktionsverfahrens.

4.4 Auswertung der Prognosen

Die Prognosegüte wird anhand von Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) und NASA-Score bewertet. Der NASA-Score berücksichtigt, dass eine Überschätzung der verbleibenden Nutzungsdauer eine spätere Wartung nahelegen kann, und gewichtet diesen Fehler stärker als eine gleich große Unterschätzung (Saxena et al., n. d., S. 7–8). Für den Hauptvergleich ist eine Auswertung am letzten verfügbaren Zeitpunkt jedes Testtriebwerks vorgesehen.

Die Ergebnisse auf den fehlerhaften Daten werden mit denen der unveränderten Daten verglichen. Neben den absoluten Prognosefehlern wird ihre Zunahme betrachtet. Dadurch lässt sich unterscheiden, ob ein Modell unter einer Störung weiterhin brauchbare Prognosen liefert oder sich nur deshalb wenig verschlechtert, weil es bereits auf den unveränderten Daten ungenau ist. Wiederholte Versuche und Konfidenzintervalle sollen helfen, die Streuung der Ergebnisse einzuordnen. Bei der statistischen Auswertung werden mehrere Beobachtungen desselben Triebwerks nicht als voneinander unabhängige Maschinen behandelt.

4.5 Messungen in der Cloud

Die Modelle werden nacheinander über eine gemeinsame Schnittstelle in die Cloud-Pipeline eingebunden. Für den Hauptvergleich sollen sie unter denselben Hardware- und Lastbedingungen laufen. Welche Instanz dafür geeignet ist und ob eine GPU verwendet wird, wird im technischen Vorversuch entschieden. Gemessen werden die Dauer einzelner Prognosen, der erreichbare Durchsatz sowie der

Ressourcenbedarf für Central Processing Unit (CPU), Random Access Memory (RAM) und gegebenenfalls GPU.

Die reine Modellinferenz wird getrennt von der gesamten Verarbeitung im Prognosedienst gemessen. Diese umfasst auch die Datenaufbereitung und die Merkmalerzeugung. Die genauen Messpunkte und Lastprofile werden vor den Messreihen festgelegt. Mehrere Durchläufe sollen Schwankungen der Cloud-Umgebung berücksichtigen, die auch bei gleicher Instanzkonfiguration auftreten können (Leitner & Cito, 2016).

Die Kosten werden aus den verwendeten Cloud-Komponenten und der gemessenen Ressourcennutzung beziehungsweise Laufzeit abgeleitet. Für den Modellvergleich sollen sie auf die Zahl der erzeugten Prognosen bei einer angegebenen Last bezogen werden. Kosten des laufenden Betriebs werden von denen für Training und Modellauswahl getrennt. Das ursprüngliche Vortraining von MOMENT wird nicht als eigener Aufwand berechnet. Bei den Inferenzmessungen wird der Encoder jedoch berücksichtigt.

4.6 Nachvollziehbarkeit und Grenzen

Datenaufteilungen, erzeugte Sensorfehler, Modelleinstellungen, Softwareversionen und Cloud-Konfiguration werden dokumentiert, damit die Versuche nachvollziehbar sind. Mögliche Überschneidungen zwischen C-MAPSS und den Vortrainingsdaten von MOMENT werden geprüft und bei der Einordnung der Ergebnisse berücksichtigt.

Die Untersuchung verwendet simulierte Triebwerksdaten und künstlich erzeugte Störungen. Sie bildet daher nicht alle Bedingungen realer Anlagen oder Kommunikationsnetze ab. Auch die Ergebnisse zu Aufwand und Kosten gelten zunächst nur für die gewählte Cloud-Umgebung. Aus dem Vergleich von MOMENT-1-small mit zwei für diese Aufgabe trainierten Modellen lassen sich keine allgemeinen Aussagen über alle TSFM ableiten.

4.7 Geplanter Aufbau der Masterarbeit

Die spätere Masterarbeit soll zunächst das Problem und den Stand des Wissens erläutern und daraus die Forschungsfrage ableiten. Danach folgen die Datengrundlage und das methodische Vorgehen. Ein Implementierungskapitel beschreibt den Versuchsaufbau, die Erzeugung der Sensorfehler und die Einbindung der Modelle in die Cloud-Pipeline.

Die Ergebnisse werden getrennt nach Prognosequalität, Verhalten unter Sensorfehlern und Cloud-Betrieb dargestellt. In der Diskussion werden diese Ergebnisse zusammengeführt und ihre Grenzen erläutert. Den Abschluss bilden die Beantwortung der Forschungsfrage und ein Ausblick auf weitere Untersuchungen.

5 ERWARTETE ERGEBNISDARSTELLUNG

Dieses Kapitel beschreibt, wie die Ergebnisse später dargestellt werden.

Zunächst werden die Prognosefehler auf den unveränderten Testdaten gegenübergestellt. Danach sollen Diagramme zeigen, wie sich die Ergebnisse bei zunehmenden Datenfehlern verändern. Die Streuung zwischen den Versuchsläufen und geeignete Konfidenzintervalle helfen dabei, die Unterschiede einzuordnen. Ergebnisse der beiden Teildatensätze werden getrennt dargestellt.

Die Messungen zum Cloud-Betrieb werden in Tabellen und Diagrammen zusammengefasst. Ein Vergleich von Prognosefehlern und Betriebskosten soll zeigen, ob eine genauere Prognose mit zusätz-

zlichem Aufwand verbunden ist. Daraus soll eine Einschätzung der Stärken und Schwächen der verschiedenen Modelle unter Berücksichtigung der untersuchten Bedingungen entstehen.

6 ERWARTETER BEITRAG UND AUSBLICK

Die Arbeit soll eine Grundlage für die Auswahl eines RUL-Modells schaffen, wenn im Betrieb mit unzuverlässigen Sensordaten zu rechnen ist. Dazu werden die Prognosequalität und der Aufwand der drei Modelle unter gemeinsamen Bedingungen verglichen. Vorausgesetzt wird nicht, dass MOMENT-1-small einen Vorteil hat. Sollte das Modell bei ähnlicher oder schlechterer Genauigkeit mehr Ressourcen benötigen, wäre auch dies ein wichtiges Ergebnis für die Entscheidung über seinen Einsatz.

Weitere Untersuchungen könnten prüfen, ob sich die Ergebnisse mit realen Industriedaten oder anderen TSFM bestätigen. Auch ein gezieltes Training mit fehlerhaften Daten und eine aufwendigere Rekonstruktion fehlender Werte wären mögliche Erweiterungen. Welche davon besonders sinnvoll sind, lässt sich nach den geplanten Versuchen genauer beurteilen.

Abkürzungen

BRITS	Bidirectional Recurrent Imputation for Time Series
C-MAPSS	Commercial Modular Aero-Propulsion System Simulation
CNN	Convolutional Neural Network
CPU	Central Processing Unit
GPU	Graphics Processing Unit
GRU	Gated Recurrent Unit
GRU-D	Gated Recurrent Unit with Decay
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
NASA	National Aeronautics and Space Administration
RAM	Random Access Memory
RMSE	Root Mean Squared Error
RUL	Remaining Useful Life
TCN	Temporal Convolutional Network
TimesFM	Time Series Foundation Model
TSFM	Time-Series Foundation Model

Literaturverzeichnis

- Amin, A. A., Mubarak, A., Waseem, S., Alqarni, Z. A., & Manzoor, H. U. (2026). Remaining Useful Life (RUL) Prediction Methods for Machine Health Estimation and Fault Diagnosis: A Comprehensive Review of Latest Techniques and Future Prospects. *Engineering Reports*, 8(4), e70699. <https://doi.org/10.1002/eng2.70699>
- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Arango, S. P., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Torkkola, K., Wilson, A. G., & Bohlke-Schneider, M. (n. d.). Chronos: Learning the Language of Time Series.
- Berghout, T., & Benbouzid, M. (2022). A Systematic Guide for Predicting Remaining Useful Life with Machine Learning. *Electronics*, 11(7), 1125. <https://doi.org/10.3390/electronics11071125>
- Bergstra, J., Bergstra, J., Bengio, Y., & Bengio, Y. (n. d.). Random Search for Hyper-Parameter Optimization.
- Bouthillier, X., Delaunay, P., Bronzi, M., Trofimov, A., Nichyporuk, B., Szeto, J., Sepah, N., Raff, E., Madan, K., Voleti, V., Kahou, S. E., Michalski, V., Serdyuk, D., Arbel, T., Pal, C., Varoquaux, G., & Vincent, P. (n. d.). Accounting for Variance in Machine Learning Benchmarks.
- Cao, W., Wang, D., Li, J., Zhou, H., Li, L., & Li, Y. (n. d.). BRITS: Bidirectional Recurrent Imputation for Time Series.
- Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent Neural Networks for Multivariate Time Series with Missing Values. *Scientific Reports*, 8(1), 6085. <https://doi.org/10.1038/s41598-018-24271-9>
- Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A Decoder-Only Foundation Model for Time-Series Forecasting. *Proceedings of the 41st International Conference on Machine Learning*, 10148–10167. Verfügbar 2. Oktober 2026 unter <https://proceedings.mlr.press/v235/das24c.html>
- Dintén, R., & Zorrilla, M. (2025). Using Time Series Foundation Models for Few-Shot Remaining Useful Life Prediction of Aircraft Engines. *Computer Modeling in Engineering & Sciences*, 144(1), 239–265. <https://doi.org/10.32604/cmescs.2025.065461>
- El-Ghoussani, A., Vita, M. D., Naumann, R., & Belagiannis, V. (2026, 11. August). *Time-Series Foundation Model Embeddings for Remaining Useful Life Estimation*. arXiv: 2606.11990 [cs.LG]. <https://doi.org/10.48550/arXiv.2606.11990>
- Goswami, M., Szafer, K., Choudhry, A., Cai, Y., Li, S., & Dubrawski, A. (2024). MOMENT: A Family of Open Time-Series Foundation Models. *Proceedings of the 41st International Conference on Machine Learning*, 16115–16152. Verfügbar 27. September 2026 unter <https://proceedings.mlr.press/v235/goswami24a.html>
- Henderson, P., Hu, J., Romoff, J., Brunskill, E., Jurafsky, D., & Pineau, J. (n. d.). Towards the Systematic Reporting of the Energy and Carbon Footprints of Machine Learning.
- Hu, Y., Liu, S., Lu, H., & Zhang, H. (2019). Remaining Useful Life Model and Assessment of Mechanical Products: A Brief Review and a Note on the State Space Model Method. *Chinese Journal of Mechanical Engineering*, 32(1), 15. <https://doi.org/10.1186/s10033-019-0317-y>
- Ji, S., Han, X., Hou, Y., Song, Y., & Du, Q. (2020). Remaining Useful Life Prediction of Airplane Engine Based on PCA–BLSTM. *Sensors*, 20(16), 4537. <https://doi.org/10.3390/s20164537>
- Kapoor, S., & Narayanan, A. (2023). Leakage and the Reproducibility Crisis in Machine-Learning-Based Science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>

- Leitner, P., & Cito, J. (2016). Patterns in the Chaos—A Study of Performance Variation and Predictability in Public IaaS Clouds. *ACM Trans. Internet Technol.*, 16(3), 15:1–15:23. <https://doi.org/10.1145/2885497>
- Li, X., Ding, Q., & Sun, J.-Q. (2018). Remaining Useful Life Estimation in Prognostics Using Deep Convolution Neural Networks. *Reliability Engineering & System Safety*, 172, 1–11. <https://doi.org/10.1016/j.ress.2017.11.021>
- Listou Ellefsen, A., Bjørlykhaug, E., Æsøy, V., Ushakov, S., & Zhang, H. (2019). Remaining Useful Life Predictions for Turbofan Engine Degradation Using Semi-Supervised Deep Architecture. *Reliability Engineering & System Safety*, 183, 240–251. <https://doi.org/10.1016/j.ress.2018.11.027>
- Saxena, A., Simon, D., & Eklund, N. (n. d.). Damage Propagation Modeling for Aircraft Engine Prognostics.
- Tang, D. (2026). A Deep Learning Framework for Remaining Useful Life Prediction of Turbofan Engines with Partial Sensor Failure. *PLOS ONE*, 21(4), e0347312. <https://doi.org/10.1371/journal.pone.0347312>
- Verbert, K., De Schutter, B., & Babuška, R. (2017). Timely Condition-Based Maintenance Planning for Multi-Component Systems. *Reliability Engineering & System Safety*, 159, 310–321. <https://doi.org/10.1016/j.ress.2016.10.032>
- Vogl, G. W., Weiss, B. A., & Helu, M. M. (2016). A Review of Diagnostic and Prognostic Capabilities and Best Practices for Manufacturing. *Journal of Intelligent Manufacturing*. <https://doi.org/10.1007/s10845-016-1228-8>
- Wang, H., Peng, M., Xu, R., Ayodeji, A., & Xia, H. (2020). Remaining Useful Life Prediction Based on Improved Temporal Convolutional Network for Nuclear Power Plant Valves. *Frontiers in Energy Research*, 8. <https://doi.org/10.3389/fenrg.2020.584463>
- Wen, G.-H., & Chen, K.-Y. (2026, 24. August). *Do Time-Series Foundation Models Pay Off for Industrial Monitoring? A Cost-Aware Empirical Study*. arXiv: 2608.22968 [cs.LG]. <https://doi.org/10.48550/arXiv.2608.22968>
- Wu, F., Wu, Q., Tan, Y., & Xu, X. (2024). Remaining Useful Life Prediction Based on Deep Learning: A Survey. *Sensors*, 24(11), 3454. <https://doi.org/10.3390/s24113454>
- Zhang, K., & Liu, R. (2023). LSTM-Based Multi-Task Method for Remaining Useful Life Prediction under Corrupted Sensor Data. *Machines*, 11(3), 341. <https://doi.org/10.3390/machines11030341>
- Zonta, T., da Costa, C. A., da Rosa Righi, R., de Lima, M. J., da Trindade, E. S., & Li, G. P. (2020). Predictive Maintenance in the Industry 4.0: A Systematic Literature Review. *Computers & Industrial Engineering*, 150, 106889. <https://doi.org/10.1016/j.cie.2020.106889>