Restlebensdauerprognose mit Time-Series Foundation Models bei Datenfehlern

Jan Moritz
FH-Burgenland, Eisenstadt, Österreich

KURZFASSUNG

Bei der datenbasierten Instandhaltung wird die verbleibende Nutzungsdauer einer Maschine, die Remaining Useful Life (RUL), aus Sensordaten geschätzt, die im Betrieb unvollständig oder durch Messfehler verändert sein können. Erste Studien untersuchen für diese Aufgabe den Einsatz von Time-Series Foundation Models (TSFM), die bereits auf großen Zeitreihensammlungen vortrainiert wurden. In der bisherigen Literaturrecherche wurde kein direkter Vergleich gefunden, der gleiche künstlich erzeugte Sensorfehler zugrunde legt und zugleich die Prognosequalität und den Aufwand des Cloud-Betriebs erfasst.

Die geplante Arbeit vergleicht MOMENT-1-small mit einem Long Short-Term Memory (LSTM) und einem Temporal Convolutional Network (TCN). Dabei wird MOMENT als unveränderter Merkmalsextraktor mit trainierbarem Regressionskopf eingesetzt. Als Datengrundlage dienen die Teilmengen FD001 und FD003 des mit Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) erzeugten Datensatzes der National Aeronautics and Space Administration (NASA). Für die RUL-Prognose werden die Modelle ohne zusätzliche Sensorfehler trainiert und ihre Einstellungen anhand von Validierungsdaten ausgewählt. Danach werden fehlende Einzelwerte, Übertragungslücken, Sensorausfälle und Sensordrift in die Testdaten eingebracht, um die Entwicklung der Prognosefehler gegenüber den unveränderten Daten zu untersuchen. Die Bewertung erfolgt anhand von Mean Absolute Error (MAE), Root Mean Squared Error (RMSE) und NASA-Score sowie ergänzenden Messungen zu Latenz, Durchsatz, Ressourcenbedarf und Kosten des Cloud-Betriebs.

Die Ergebnisse sollen zeigen, ob MOMENT-1-small bei fehlerhaften Sensordaten Vorteile bietet und welcher Aufwand damit unter den untersuchten Versuchsbedingungen verbunden ist.

1 EINLEITUNG UND PROBLEMHINTERGRUND

1.1 Forschungsfeld

Industrie 4.0 bezeichnet die zunehmende digitale Vernetzung von Maschinen, Produktionsanlagen und den zugehörigen Informationssystemen. Sensoren erfassen laufend den Betriebszustand einer Anlage und stellen damit Daten bereit, die zwischen Systemen ausgetauscht und für Entscheidungen in der Produktion genutzt werden können. Cloud-Infrastrukturen ermöglichen es, diese Daten gemeinsam zu speichern und zu verarbeiten (Zonta et al., 2020, S. 1–2).

Ein Anwendungsgebiet dieser Vernetzung ist Predictive Maintenance, bei der Zustands- und Betriebsdaten ausgewertet werden, um Veränderungen früh zu erkennen und Wartungen vorausschauend zu planen. Wartungsentscheidungen orientieren sich dadurch stärker an der Entwicklung des Maschinenzustands als an festen Zeitintervallen. Dies kann ungeplante Stillstände und die damit verbundenen Instandhaltungskosten reduzieren (Zonta et al., 2020, S. 1–2, 7).

Eine wichtige Größe für diese Planung ist die Remaining Useful Life (RUL), die die geschätzte Zeit beziehungsweise Anzahl an Betriebszyklen bis zu einer festgelegten Ausfallgrenze beschreibt. Dazu wird aus dem bisher beobachteten Zustand einer Maschine oder Komponente auf ihre weitere Entwicklung geschlossen. Eine verlässliche Prognose kann damit die Entscheidung unterstützen, wann eine Wartung oder ein Austausch notwendig ist (Hu et al., 2019, S. 2).

Für die datenbasierte RUL-Prognose werden unter anderem Long Short-Term Memory (LSTM), Gated Recurrent Units (GRU), Convolutional Neural Networks (CNN) und Temporal Convolutional Networks (TCN) eingesetzt (Wu et al., 2024, S. 15–16). Die Modelle werden anhand historischer Sensordaten trainiert und lernen zeitliche Zusammenhänge zwischen den Messwerten und der verbleibenden Nutzungsdauer. Wiederkehrende Veränderungen der Sensorverläufe können dabei Hinweise auf eine fortschreitende Schädigung liefern. Rekurrente Modelle wie LSTM und GRU sowie Verfahren mit zeitlichen Faltungen bieten unterschiedliche Möglichkeiten, solche Verläufe zu verarbeiten (Wang et al., 2020, S. 3, 6).

1.2 Problemstellung

Ein verbreiteter Benchmark ist der mit Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) erzeugte Datensatz der National Aeronautics and Space Administration (NASA), der simulierte Sensordaten von Turbofan-Triebwerken mit Trainingsverläufen bis zum Ausfall enthält. Während in diesen Messreihen keine Sensorwerte fehlen, können in realen Anwendungen Sensor- und Kommunikationsfehler einzelne Messwerte oder ganze Sensorkanäle ausfallen lassen. Hinzu kommen mögliche systematische Messabweichungen und Sensordrift, durch die sich Messwerte zunehmend vom tatsächlichen Zustand entfernen. Solche Störungen können die RUL-Prognose verschlechtern und werden daher bereits durch gezielte Veränderungen der Benchmarkdaten untersucht (Tang, 2026, S. 7–10).

Neben den etablierten Modellen werden inzwischen Time-Series Foundation Models (TSFM) wie MOMENT untersucht, die auf umfangreichen Zeitreihensammlungen aus unterschiedlichen Anwendungsbereichen vortrainiert werden. Die dabei erlernten Merkmale beschreiben Eigenschaften der Zeitreihen und können anschließend für weitere Aufgaben verwendet werden (Goswami et al., 2024, S. 1–4). Dintén und Zorrilla nutzen diese Merkmale bereits für die RUL-Prognose auf

C-MAPSS, untersuchen jedoch keine beschädigten Testdaten (Dintén & Zorrilla, 2025, S. 246, 252–255). El-Ghoussani et al. kombinieren Chronos-2 mit einem kleinen Regressionskopf zur Ableitung eines RUL-Werts und nennen die Robustheit bei fehlenden Sensoren als offene Forschungsfrage (El-Ghoussani et al., 2026, S. 2–4).

1.3 Bedarf an einem vergleichbaren Versuch

Für die Auswahl eines Modells reicht die Prognosegüte auf vollständigen Daten allein nicht aus, wenn im späteren Betrieb mit fehlerhaften Messwerten zu rechnen ist. Benötigt wird auch eine Einschätzung, wie sich die Prognosen bei nachlassender Datenqualität verändern, wobei alle Modelle dieselben Fehlerarten und Fehlerstärken erhalten müssen. Für den Cloud-Betrieb ist zusätzlich relevant, wie viel Rechenleistung die Prognosen benötigen und welche Kosten dabei entstehen. Ein Vergleich unter gemeinsamen Versuchsbedingungen soll diese Informationen zusammenführen und damit eine Grundlage für die Modellwahl schaffen.

1.4 Ziel der Arbeit

Die geplante Arbeit vergleicht deshalb MOMENT-1-small mit einem LSTM und einem TCN unter gezielt veränderten Testbedingungen. Bei MOMENT erzeugt der vortrainierte Encoder Merkmale aus den Messverläufen und bleibt während des aufgabenspezifischen Trainings unverändert. Nur ein zusätzlicher Regressionskopf wird darauf trainiert, aus diesen Merkmalen einen RUL-Wert abzuleiten. Fehlende Messwerte, Übertragungslücken, Sensorausfälle und Drift sollen zeigen, wie empfindlich die Modelle auf eine nachlassende Datenqualität reagieren. Neben der Prognosegüte werden Latenz, Ressourcenbedarf und Kosten des Cloud-Betriebs untersucht, um mögliche Genauigkeitsvorteile auch hinsichtlich des dafür erforderlichen Aufwands beurteilen zu können.

2 STAND DES WISSENS / STAND DER TECHNIK

Die für diese Arbeit relevante Literatur wird in vier Bereiche gegliedert: Verfahren zur RUL-Prognose, vortrainierte Zeitreihenmodelle, der Umgang mit fehlerhaften Sensordaten und der Rechenaufwand der Modelle. Aus diesen Bereichen wird anschließend der Untersuchungsbedarf abgeleitet.

2.1 Verfahren zur Prognose der Remaining Useful Life

Predictive Maintenance nutzt Zustandsdaten von Maschinen, um Veränderungen frühzeitig zu erkennen und Wartungen vorausschauend zu planen (Zonta et al., 2020). Dafür werden diagnostische und prognostische Verfahren benötigt, die den aktuellen Zustand einer Maschine bewerten und ihre weitere Entwicklung vorhersagen (Vogl et al., 2016). Bei der Planung muss auch der wirtschaftliche Nutzen berücksichtigt werden, da eine technisch mögliche Wartung nicht zu jedem Zeitpunkt sinnvoll ist (Verbert et al., 2017).

Eine wichtige Prognosegröße ist die RUL, die mit physikalischen, datenbasierten oder hybriden Verfahren geschätzt werden kann (Hu et al., 2019). Übersichten von Berghout und Benbouzid (2022) und Wu et al. (2024) beschreiben den Einsatz tiefer neuronaler Netze für diese Aufgabe. Trotz der Fortschritte bestehen weiterhin Probleme bei der Datenqualität, der Vergleichbarkeit der Versuche und der Übertragung auf andere Anlagen (Amin et al., 2026).

Viele dieser Verfahren werden mit C-MAPSS bewertet, das simulierte Verläufe von Turbofan-Triebwerken mit unterschiedlichen Betriebs- und Fehlerbedingungen enthält (Saxena et al., 2008). Für die Verarbeitung der zeitlichen Zusammenhänge verwenden Ji et al. ein bidirektionales LSTM, dem eine Hauptkomponentenanalyse zur Verringerung der Merkmalszahl vorgeschaltet ist (Ji et al., 2020). Einen Ansatz zur Nutzung weniger gelabelter Trainingsverläufe verfolgen Listou Ellefsen et al., indem sie unüberwachtes Vortraining mit einer überwachten RUL-Schätzung verbinden (Listou Ellefsen et al., 2019).

Andere Ansätze nutzen Faltungen, um Muster innerhalb zeitlicher Abschnitte der Sensordaten zu erkennen. Li et al. setzen dafür ein tiefes CNN ein, das aufeinanderfolgende Messwerte in Eingabefenstern verarbeitet (Li et al., 2018). Wang et al. verbinden dagegen einen Convolutional Autoencoder zur Merkmalsgewinnung mit einem TCN und prüfen diesen Ansatz ebenfalls auf C-MAPSS (Wang et al., 2020, S. 6–10). Die Arbeiten belegen die Eignung unterschiedlicher Modellarchitekturen für die RUL-Prognose, untersuchen deren Verhalten jedoch überwiegend anhand vollständiger Sensorkanäle.

2.2 Vortrainierte Zeitreihenmodelle

TSFM werden auf großen Sammlungen unterschiedlicher Zeitreihen vortrainiert und können anschließend für neue Aufgaben verwendet werden. Chronos ordnet Messwerte diskreten Wertebereichen zu, stellt diese als Tokens dar und nutzt Sprachmodellarchitekturen für probabilistische Prognosen (Ansari et al., 2024). TimesFM teilt die Eingabe in Abschnitte und erzeugt mit einem Decoder Prognosen für zuvor unbekannte Datensätze (Das et al., 2024). Während diese Ansätze vor allem zukünftige Messwerte vorhersagen, unterstützt MOMENT auch die Ergänzung fehlender Werte, die sogenannte Imputation, sowie Klassifikation und Anomalieerkennung. Eine RUL-Regression wird in der ursprünglichen Untersuchung jedoch nicht betrachtet (Goswami et al., 2024, S. 3–5).

Für die RUL-Prognose untersuchen Dintén und Zorrilla MOMENT als unveränderten Merkmalsextraktor für C-MAPSS. Bei kleinen Trainingsmengen zeigen sich Vorteile für einzelne nachgeschaltete Modelle, jedoch nicht für alle untersuchten Verfahren, und fehlerhafte Sensordaten werden nicht berücksichtigt (Dintén & Zorrilla, 2025, S. 246, 252–255). El-Ghoussani et al. verbinden Chronos-2 mit einem trainierbaren Regressionskopf und vergleichen den Ansatz mit LSTM, GRU und TCN. Längere Datenlücken werden aus der Auswertung entfernt, sodass die Robustheit gegenüber solchen Fehlern offenbleibt (El-Ghoussani et al., 2026, S. 2–4). Beide Arbeiten verwenden vortrainierte Merkmale für eine nachgeschaltete RUL-Schätzung, enthalten jedoch keinen kontrollierten Vergleich bei zunehmenden Sensorfehlern.

2.3 Umgang mit fehlerhaften Sensordaten

Fehlende Werte in Zeitreihen werden auch unabhängig von der RUL-Prognose untersucht, wobei sich die Verfahren in der Nutzung der verfügbaren Beobachtungen unterscheiden. Gated Recurrent Unit with Decay (GRU-D) berücksichtigt Masken zur Kennzeichnung fehlender Werte und die Zeit seit der letzten vorhandenen Beobachtung (Che et al., 2018). Bidirectional Recurrent Imputation for Time Series (BRITS) verarbeitet eine Zeitreihe dagegen vorwärts und rückwärts, um fehlende Werte aus früheren und späteren Beobachtungen zu schätzen (Cao et al., 2018). Beide Verfahren wurden nicht für die RUL-Prognose auf C-MAPSS entwickelt.

Speziell für die RUL-Prognose verbinden Zhang und Liu die Rekonstruktion fehlender Werte mit der Schätzung der Restlebensdauer in einem CNN-LSTM-Modell. Die Trainingsdaten werden bereits künstlich beschädigt, sodass das Modell die untersuchten Fehlermuster beim Training kennenlernt (Zhang & Liu, 2023, S. 4–6, 9–14). Tang untersucht Datenverluste, Sensorausfälle, Messabweichungen und Drift mit einem generativen Modell, das die Sensordaten vor der anschließenden RUL-Schätzung rekonstruiert. Ein Vergleich mit einem TSFM ist darin nicht enthalten (Tang, 2026, S. 3–6, 9–10, 19).

Die Verfahren unterscheiden sich darin, ob sie fehlende Werte allgemein ergänzen oder deren Rekonstruktion mit einer RUL-Schätzung verbinden. Für den geplanten Modellvergleich ist diese Unterscheidung relevant: Bei einer gemeinsamen einfachen Ergänzungsregel lässt sich untersuchen, wie die drei Prognosemodelle unter denselben Fehlerbedingungen reagieren.

2.4 Rechenaufwand und Cloud-Betrieb

Neben der Prognosequalität ist der Rechenaufwand der Modelle relevant, weshalb Henderson et al. eine nachvollziehbare Dokumentation von Rechenzeit, verwendeter Hardware und Energiebedarf empfehlen (Henderson et al., 2020). Auch in den RUL-Studien werden solche Fragen teilweise aufgegriffen, etwa durch die Angabe von Trainings- und Inferenzzeiten bei Dintén und Zorrilla (Dintén & Zorrilla, 2025, S. 255). Tang untersucht ebenfalls den Aufwand seines Verfahrens zur RUL-Prognose unter Sensorfehlern (Tang, 2026, S. 19).

Einen direkten Vergleich von TSFM mit kleineren Modellen führen Wen und Chen durch. In ihrem C-MAPSS-Versuch erzielt ein TCN-Autoencoder bessere Klassifikationsergebnisse als MOMENT und benötigt weniger Rechenzeit und Speicher auf der Graphics Processing Unit (GPU). Da Risikoklassen statt RUL-Werten vorhergesagt werden, lässt sich das Ergebnis nicht direkt auf die RUL-Regression übertragen (Wen & Chen, 2026, S. 2–5).

Diese Untersuchungen liefern Hinweise auf Unterschiede im Rechenaufwand. Für eine Bewertung der Betriebskosten in der Cloud müssen zusätzlich die eingesetzte Infrastruktur und die Zahl der unter einer bestimmten Last erzeugten Prognosen berücksichtigt werden. Die geplante Arbeit ergänzt die Qualitätsbewertung deshalb um Messungen unter dokumentierten Cloud-Bedingungen.

2.5 Einordnung der geplanten Arbeit

Die bisherigen Arbeiten zeigen, dass sowohl die RUL-Prognose mit TSFM als auch der Umgang mit fehlerhaften Sensordaten bereits untersucht werden. Einzelne Studien berücksichtigen dabei auch den Rechenaufwand. In der bisherigen Literaturrecherche wurde jedoch kein Vergleich gefunden, der MOMENT, LSTM und TCN für die RUL-Prognose mit denselben gezielt veränderten Testdaten untersucht und zugleich den Aufwand ihres Cloud-Betriebs erfasst. Offen bleibt damit, wie sich die Prognosequalität dieser Modellansätze bei zunehmenden Datenfehlern verändert und welcher Ressourcenbedarf damit verbunden ist. Die geplante Arbeit untersucht diesen Zusammenhang unter gemeinsamen Versuchsbedingungen. Ihr Beitrag liegt im Vergleich der Modelle, nicht in der Entwicklung eines neuen Prognosemodells.

3 WISSENSCHAFTLICHE FRAGESTELLUNG

Diese Arbeit untersucht, wie gut sich MOMENT-1-small für eine cloudbasierte RUL-Prognose mit fehlerhaften Sensordaten eignet und welcher Betriebsaufwand damit verbunden ist. Als Vergleich dienen ein LSTM und ein TCN, die speziell für diese Aufgabe trainiert und unter denselben Testbedingungen bewertet werden. Daraus ergibt sich folgende Forschungsfrage:

> Wie unterscheiden sich MOMENT-1-small, ein LSTM und ein TCN bei der RUL-Prognose mit fehlerhaften C-MAPSS-Sensordaten hinsichtlich Prognosequalität, Robustheit, Inferenzlatenz, Ressourcenbedarf und Cloud-Kosten?

Zur Beantwortung der Forschungsfrage werden folgende Teilfragen untersucht:

1. Wie verändern sich die Prognosefehler der Modelle bei unterschiedlichen Arten und Stärken von Sensorfehlern?
2. Welche Unterschiede zeigen sich bei Inferenzlatenz, Durchsatz und Ressourcenbedarf unter vergleichbaren Betriebsbedingungen?
3. In welchem Verhältnis stehen die Kosten des Cloud-Betriebs zur erreichten Prognosequalität und Robustheit?

Die Hauptuntersuchung ist mit C-MAPSS FD001 vorgesehen, während FD003 den Vergleich um einen weiteren Teildatensatz ergänzen soll. Das Training für die RUL-Prognose erfolgt ohne zusätzlich erzeugte Sensorfehler, die erst in die Testdaten eingebracht werden, um eine nachlassende Datenqualität im Betrieb nachzubilden. Eine nachträgliche Anpassung der Modelle an diese Testfehler ist nicht vorgesehen.

4 FORSCHUNGSMETHODIK

Die Arbeit vergleicht MOMENT-1-small, LSTM und TCN hinsichtlich ihrer RUL-Prognosen und des Aufwands für ihren Betrieb in der Cloud. Dazu werden die Sensordaten aufbereitet, die Modelle trainiert und anschließend mit vollständigen sowie gezielt veränderten Testdaten ausgewertet. Alle Modelle erhalten innerhalb eines Vergleichs dieselben Daten und werden unter denselben Fehlerbedingungen untersucht, damit die Ergebnisse miteinander vergleichbar sind. Abb. 1 zeigt die Reihenfolge der einzelnen Schritte und ihre Zuordnung zu den Teilfragen.

Die Untersuchung besteht aus zwei Teilen, die unterschiedliche Aspekte der Modellwahl beantworten. Zunächst wird geprüft, wie stark die Prognosefehler bei zunehmenden Datenfehlern gegenüber den unveränderten Testdaten ansteigen. Danach werden die ausgewählten Modelle in die Cloud-Pipeline eingebunden, um Latenz, Durchsatz, Ressourcenbedarf und Betriebskosten unter gemeinsamen Bedingungen zu messen. Die Ergebnisse beider Teile werden abschließend zusammengeführt, um mögliche Genauigkeitsvorteile dem dafür erforderlichen Betriebsaufwand gegenüberzustellen.

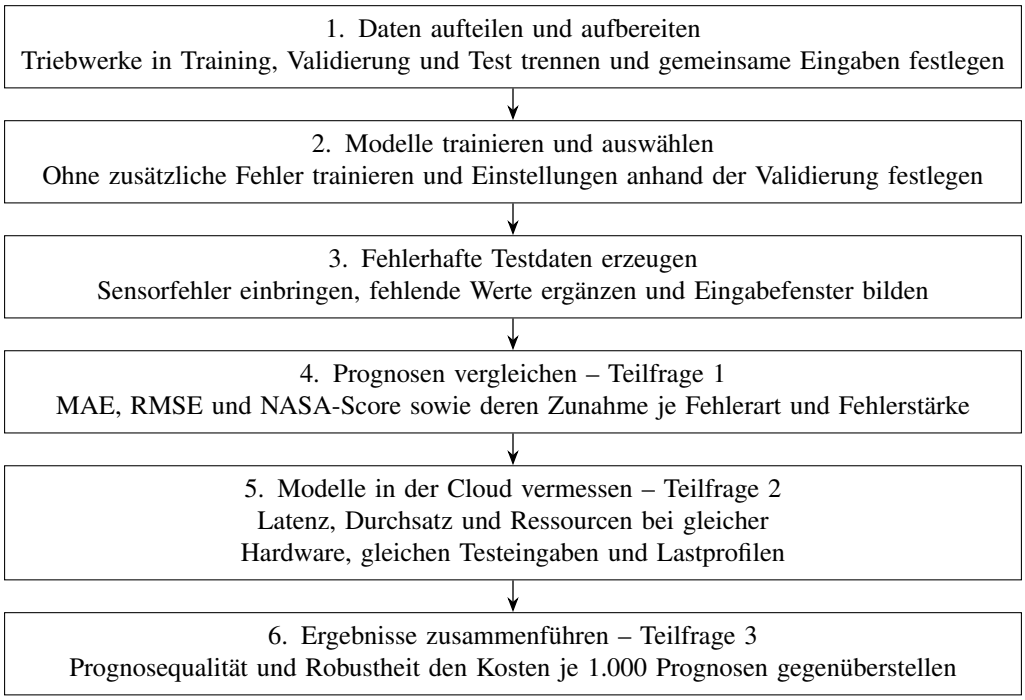


Abb. 1: Geplanter Versuchsablauf und Zuordnung zu den Teilfragen (eigene Darstellung).

4.1 Datengrundlage und Aufbereitung

Als Datengrundlage dient C-MAPSS, das simulierte Sensorverläufe von Turbofan-Triebwerken enthält, deren Schädigung bis zu einer festgelegten Ausfallgrenze fortschreitet (Saxena et al., 2008, S. 1–2, 7). Für die Hauptuntersuchung ist FD001 vorgesehen, während FD003 den Vergleich auf einen

weiteren Teildatensatz ausdehnen soll. Eine Untersuchung aller Betriebsbedingungen von C-MAPSS ist nicht geplant.

Die vorgegebene Aufteilung in Trainings- und Testtriebwerke bleibt erhalten, wobei ein Teil der Trainingstriebwerke für die Validierung zurückgehalten wird. An den Trainingsdaten lernen die Modelle den Zusammenhang zwischen den Sensormessungen und der verbleibenden Nutzungsdauer. Die Validierungsdaten dienen zur Auswahl der Modelleinstellungen, während die Testdaten erst für die abschließende Bewertung der ausgewählten Modelle verwendet werden. Die Trennung erfolgt nach Triebwerken, damit ähnliche Ausschnitte derselben Maschine nicht zugleich beim Lernen und bei der Bewertung vorkommen. Dadurch soll Data Leakage vermieden werden, das die gemessene Modellleistung durch Informationen aus den späteren Auswertungsdaten überschätzen kann (Kapoor & Narayanan, 2023, S. 4–5).

Nach dieser Aufteilung werden die Zeitreihen in Eingabefenster zerlegt, die jeweils die Sensormessungen aus einer festgelegten Zahl aufeinanderfolgender Betriebszyklen enthalten. Für das Ende jedes Fensters wird aus dem Datensatz ein RUL-Zielwert bestimmt, mit dem die Prognose beim Training und bei der Auswertung verglichen wird. Als Eingabe erhält das Modell nur die Sensormessungen und nicht den zugehörigen Zielwert. Alle Modelle verwenden dieselben Sensoren, dieselbe Fensterlänge und dieselbe Zieldefinition einschließlich einer möglichen Obergrenze für hohe RUL-Werte. Diese Festlegungen werden vor dem Training getroffen und für die Auswertung beibehalten.

Die Sensorwerte werden skaliert, um unterschiedliche Größenordnungen der Messwerte bei der Verarbeitung zu berücksichtigen. Die Auswahl der Sensoren und die Bestimmung der Skalierungsparameter erfolgen ausschließlich anhand der Trainingsdaten, anschließend werden dieselben Regeln auf Validierungs- und Testdaten angewendet. Modellinterne Schritte wie eine zusätzliche Normalisierung oder das Auffüllen auf die benötigte Eingabelänge werden getrennt dokumentiert, ohne zusätzliche vergangene oder zukünftige Messwerte einzubeziehen.

4.2 Modelle und Training

MOMENT-1-small wird als vortrainierter Merkmalsextraktor eingesetzt, dessen Encoder die Sensorverläufe in Merkmalsvektoren umwandelt. Ein solcher Vektor enthält Zahlen, die gelernte Eigenschaften des jeweiligen Verlaufs beschreiben und als Eingabe für die weitere Prognose dienen. Für jeden Sensorkanal wird ein Vektor erzeugt, anschließend werden die Vektoren in einer festen Sensorreihenfolge zu einem gemeinsamen Vektor verkettet. Der Regressionskopf lernt anhand dieses Vektors und der bekannten Zielwerte, eine RUL-Schätzung auszugeben, während die bereits gelernten Parameter des Encoders unverändert bleiben. Die Verwendung von MOMENT-Merkmalen für eine nachgeschaltete RUL-Schätzung wurde bereits untersucht (Dintén & Zorrilla, 2025, S. 246).

Als Vergleich dienen ein LSTM und ein TCN, die ihre Modellparameter anhand der C-MAPSS-Trainingsdaten für die RUL-Prognose lernen. Sie erhalten die aufbereiteten Sensorfenster direkt, statt sie zunächst durch den MOMENT-Encoder in Merkmalsvektoren umzuwandeln. Bei MOMENT wird somit nur der Regressionskopf für diese Aufgabe trainiert, bei LSTM und TCN dagegen das gesamte Prognosemodell.

Die Modelleinstellungen, sogenannte Hyperparameter, werden mit einer begrenzten Suche ausgewählt, für die bei allen Modellen ein vergleichbares Suchbudget vorgesehen ist. Dazu gehören beispielsweise die Lernrate oder die Größe der trainierbaren Schichten, die vor einem Trainingslauf festgelegt werden. Random Search wählt zufällig Kombinationen dieser Einstellungen aus und kann bei gleichem Suchaufwand Vorteile gegenüber einer vollständigen Rastersuche bieten (Bergstra &

Bengio, 2012, S. 281–283). Die Auswahl der Modellkonfiguration richtet sich nach dem Root Mean Squared Error (RMSE) auf den Validierungsdaten, ohne dafür die Testdaten zu verwenden.

Trainingsläufe werden mit unterschiedlichen Zufallsinitialisierungen, also unterschiedlichen zufälligen Startwerten der trainierbaren Parameter, wiederholt, damit das Ergebnis nicht nur von einem einzelnen Lauf abhängt. Bei MOMENT betrifft dies den Regressionskopf, bei LSTM und TCN das gesamte Modell, da nur diese Parameter jeweils neu trainiert werden. Die Wiederholungen sollen zeigen, wie stark die Prognosequalität bei gleichbleibender Modellkonfiguration durch zufällige Einflüsse des Trainings schwankt (Bouthillier et al., 2021). Die Zahl der Wiederholungen wird unter Berücksichtigung des Rechenbudgets vor dem Training für alle Modelle einheitlich festgelegt und zusammen mit den ausgewählten Einstellungen dokumentiert.

Für das Training zur RUL-Prognose werden keine zusätzlichen Sensorfehler erzeugt. Davon zu unterscheiden ist das bereits abgeschlossene Vortraining von MOMENT, bei dem unter anderem maskierte Zeitreihen zur Rekonstruktion verwendet wurden (Goswami et al., 2024, S. 3–4). Eine erneute Anpassung der Modelle an die später untersuchten Testfehler ist nicht vorgesehen.

4.3 Fehlerexperimente

Die Testdaten werden gezielt verändert, um vier Arten fehlerhafter Telemetrie nachzubilden. Dazu werden einzelne Messwerte, zusammenhängende Abschnitte oder die Werte eines ganzen Sensorkanals für eine bestimmte Dauer als fehlend markiert. Die ursprüngliche Abfolge der Betriebszyklen bleibt dabei erhalten, damit sich die zeitliche Zuordnung der Messwerte und Zielwerte nicht verändert. Zusätzlich wird Sensordrift erzeugt, bei der sich die Messwerte zunehmend von ihrem ursprünglichen Verlauf entfernen. Jede Fehlerart wird getrennt in mehreren Stärken untersucht, deren Anteile fehlender Werte, Ausfalldauern und Driftstärken vor der Auswertung festgelegt werden.

Die unveränderten Testverläufe bilden die Referenz für den Vergleich und werden für die verschiedenen Fehlerbedingungen kopiert. Die Fehler werden vor der Bildung der Eingabefenster eingebracht, damit derselbe Messwert auch in überlappenden Fenstern auf dieselbe Weise verändert bleibt. Alle Modelle erhalten innerhalb eines Vergleichs genau dieselben fehlerhaften Daten, während die tatsächliche RUL als Zielwert unverändert bleibt. Verändert wird damit die Beobachtung des Maschinenzustands und nicht der Zeitpunkt, zu dem das simulierte Triebwerk ausfällt. Bei zufälligen Fehlern werden mehrere Fehlerrealisierungen, also unterschiedliche Muster der betroffenen Messwerte, erzeugt und die verwendeten Zufallsstartwerte dokumentiert.

Damit alle Modelle trotz fehlender Werte eine Prognose erzeugen können, werden diese durch eine gemeinsame einfache Imputation ergänzt. Dafür ist die Übernahme des zuletzt bekannten Werts desselben Sensors vorgesehen, der bis zur nächsten gültigen Messung weiterverwendet wird. Liegt zu Beginn noch kein gültiger Wert vor, wird eine zuvor aus den Trainingsdaten bestimmte Ersatzregel angewendet. Die Imputation darf ausschließlich bereits verfügbare Messungen verwenden und wird im Offline-Vergleich sowie im Cloud-Dienst mit derselben Messhistorie umgesetzt. Verglichen wird damit die Reaktion der Prognosemodelle nach einer gemeinsamen Fehlerbehandlung und nicht die Leistungsfähigkeit verschiedener Imputationsverfahren.

4.4 Auswertung der Prognosen

Zur Beantwortung der ersten Teilfrage erzeugen die ausgewählten Modelle zunächst Prognosen für die unveränderten und danach für die beschädigten Testdaten. Im Hauptvergleich wird für jedes Testtrieb-

werk das letzte verfügbare Eingabefenster verwendet und die geschätzte RUL mit dem zugehörigen bekannten Zielwert verglichen. Die Prognosegüte wird mit drei Metriken bewertet:

- Der Mean Absolute Error (MAE) beschreibt die mittlere absolute Abweichung zwischen vorhergesagter und tatsächlicher RUL in Betriebszyklen.
- Der RMSE wird ebenfalls in Betriebszyklen angegeben. Durch die Quadrierung der Fehler fallen große Abweichungen stärker ins Gewicht.
- Der NASA-Score ist ein asymmetrisches Fehlermaß. Er gewichtet eine Überschätzung der verbleibenden Nutzungsdauer stärker als eine gleich große Unterschätzung, da eine zu hohe Prognose eine spätere Wartung nahelegen kann (Saxena et al., 2008, S. 7–8).

Die Robustheit wird daran beurteilt, wie stark die Prognosefehler gegenüber den unveränderten Testdaten zunehmen. Eine geringe Zunahme spricht für eine geringere Empfindlichkeit gegenüber der jeweiligen Störung, muss aber gemeinsam mit dem absoluten Prognosefehler betrachtet werden. Ein bereits ungenaues Modell kann sich nur wenig verschlechtern und dennoch deutlich schlechtere Prognosen liefern als ein anderes Modell. Diagramme sollen deshalb für jede Fehlerart und Fehlerstärke sowohl die absoluten Fehler als auch ihre Zunahme zeigen.

Die wiederholten Trainings- und Fehlerexperimente zeigen, wie stark die Ergebnisse zwischen einzelnen Versuchsläufen schwanken. Ergänzende Konfidenzintervalle sollen die Unsicherheit der aus den untersuchten Daten geschätzten Kennwerte und Modellunterschiede verdeutlichen. Jeder Vergleich bezieht sich auf dieselben Testtriebwerke und Fehlerrealisierungen, damit Unterschiede nicht durch abweichende Eingaben entstehen. Mehrere Beobachtungen desselben Triebwerks werden statistisch nicht wie voneinander unabhängige Maschinen behandelt, da sie aus demselben Degradationsverlauf stammen. Die Ergebnisse für FD001 und FD003 werden getrennt ausgewiesen.

4.5 Messungen in der Cloud

Zur Beantwortung der zweiten Teilfrage werden die Modelle nacheinander über eine gemeinsame Schnittstelle in die Cloud-Pipeline eingebunden. Der Prognosedienst erhält jeweils ein Sensorfenster, bereitet die Eingabe für das jeweilige Modell auf und gibt dessen RUL-Schätzung zurück. Alle Modelle laufen auf derselben Cloud-Instanz, deren Hardwarekonfiguration einschließlich einer gegebenenfalls verwendeten GPU für die Messreihen beibehalten und dokumentiert wird. Bei mehreren festgelegten Laststufen werden unterschiedlich viele Anfragen pro Zeiteinheit mit denselben Testeingaben an den Dienst gesendet. Vor Messbeginn werden die Modelle geladen und mit einigen Anfragen ausgeführt, damit der laufende Betrieb und nicht der Startvorgang gemessen wird.

Die Messgrößen für den Cloud-Vergleich sind in Tab. 1 definiert und umfassen neben Latenz und Durchsatz auch Central Processing Unit (CPU)-Auslastung und Random Access Memory (RAM)-Bedarf. Bei einer GPU-Instanz kommen deren Auslastung und belegter Speicher hinzu. Für die Latenz werden der Median und das 95. Perzentil angegeben. Letzteres bezeichnet die Zeit, die von 95 % der gemessenen Anfragen nicht überschritten wird. Mehrere Durchläufe sollen Schwankungen der Cloud-Umgebung berücksichtigen, die auch bei gleicher Instanzkonfiguration auftreten können (Leitner & Cito, 2016).

Tab. 1: Metriken für den Vergleich des Cloud-Betriebs.

Metrik	Einheit	Messung
Modelllatenz	ms	Zeit für den vollständigen Modellaufruf mit aufbereiteten Eingaben, bei MOMENT einschließlich Encoder und Regressionskopf.
Dienstlatenz	ms	Zeit vom Eingang eines vollständigen Messfensters im Prognosedienst bis zur fertigen Antwort, einschließlich Aufbereitung und Modellaufruf.
Durchsatz	Prognosen/s	Zahl erfolgreich abgeschlossener Prognosen pro Sekunde bei der jeweiligen Anfragelast.
CPU-Auslastung	Prozent	Mittlere Auslastung des Prognosedienstes während der Messung, bezogen auf die zugewiesenen CPU-Kerne.
RAM-Bedarf	GiB	Mittlerer und maximaler belegter Arbeitsspeicher des Prognosedienstes während der Messung.
GPU-Auslastung	Prozent	Mittlere Auslastung der GPU während der Messung, falls eine GPU verwendet wird.
GPU-Speicher	GiB	Maximal belegter Gerätespeicher während der Messung, falls eine GPU verwendet wird.
Betriebskosten	Euro/1.000 Prognosen	Kosten der berücksichtigten Cloud-Komponenten je 1.000 abgeschlossenen Prognosen bei dokumentierter Last.

Die Modelllatenz misst die Zeit für die eigentliche Modellberechnung und umfasst bei MOMENT sowohl den Encoder als auch den Regressionskopf. Die Dienstlatenz erfasst zusätzlich die Aufbereitung und Verarbeitung innerhalb des Prognosedienstes, beginnt aber erst beim Eingang eines vollständigen Messfensters. Übertragungszeiten vom simulierten Triebwerk bis zu diesem Eingang sind deshalb nicht enthalten. Messpunkte und Lastprofile werden vor den Messreihen festgelegt und für alle Modelle gleich verwendet.

Für die dritte Teilfrage werden die Betriebskosten aus der Bereitstellungszeit, dem zugehörigen Tarif und weiteren tatsächlich verwendeten Cloud-Komponenten berechnet. Eine fest gebuchte Instanz verursacht zunächst dieselben Stundenkosten, auch wenn eines der Modelle ihre CPU weniger stark auslastet. Entscheidend ist deshalb auch, wie viele Prognosen unter der jeweiligen Anfragelast in dieser Zeit abgeschlossen werden. Die Kosten des Messzeitraums werden durch die Zahl der abgeschlossenen Prognosen geteilt und auf 1.000 Prognosen umgerechnet.

Diese Kosten werden den Prognosefehlern und ihrer Zunahme unter den untersuchten Störungen gegenübergestellt, um Genauigkeitsvorteile und Betriebsaufwand gemeinsam beurteilen zu können. Kosten für das Training und die Modellauswahl werden getrennt vom laufenden Betrieb ausgewiesen. Das ursprüngliche Vortraining von MOMENT wird nicht als eigener Aufwand berechnet, der vollständige Encoder bleibt jedoch Bestandteil aller Betriebsmessungen.

4.6 Nachvollziehbarkeit und Grenzen

Datenaufteilungen, erzeugte Sensorfehler, Modelleinstellungen, Softwareversionen und Cloud-Konfiguration werden dokumentiert, damit die Versuche nachvollziehbar sind. Mögliche Überschneidungen zwischen C-MAPSS und den Vortrainingsdaten von MOMENT werden geprüft und bei der Einordnung der Ergebnisse berücksichtigt.

Die Untersuchung verwendet simulierte Triebwerksdaten und künstlich erzeugte Störungen, weshalb sie nicht alle Bedingungen realer Anlagen oder Kommunikationsnetze abbildet. Auch die Ergebnisse zu Aufwand und Kosten gelten zunächst nur für die gewählte Cloud-Umgebung. Die verglichenen Modellansätze unterscheiden sich sowohl in ihrer Architektur als auch in ihrer Trainingsgeschichte, sodass mögliche Leistungsunterschiede nicht allein dem Vortraining zugeschrieben werden können. Aus dem Vergleich von MOMENT-1-small mit zwei für diese Aufgabe trainierten Modellen lassen sich außerdem keine allgemeinen Aussagen über alle TSFM ableiten.

5 ERGEBNISSE

Die geplanten Ergebnisse sollen eine begründete Auswahl zwischen den drei untersuchten Modellansätzen ermöglichen. Dazu wird für jede Teilfrage aus Kapitel 3 beschrieben, welche Erkenntnisse nach Abschluss der Versuche vorliegen sollen. Eine Überlegenheit eines bestimmten Modells wird dabei nicht vorausgesetzt.

Die Auswertung zur ersten Teilfrage soll zeigen, bei welchen Fehlerarten und Fehlerstärken die Prognosen der einzelnen Modelle besonders stark nachlassen. Der Vergleich mit den unveränderten Daten soll erkennen lassen, ob ein Modell auch bei Störungen noch vergleichsweise geringe Prognosefehler erreicht. Daraus lässt sich ableiten, welche Datenfehler für den jeweiligen Ansatz besonders problematisch sind und unter welchen Bedingungen seine Prognosen vergleichsweise wenig beeinträchtigt werden.

Zur zweiten Teilfrage sollen Messwerte zu Latenz, Durchsatz und Ressourcenbedarf unter gemeinsamen Cloud-Bedingungen vorliegen. Sie sollen zeigen, wie viel Aufwand die vollständige Prognose mit dem jeweiligen Modell verursacht und welche Unterschiede unter steigender Anfragelast auftreten. Damit lässt sich der Betriebsaufwand der Modelle unter den gewählten Cloud-Bedingungen einschätzen.

Zur dritten Teilfrage werden die Betriebskosten mit der erreichten Prognosequalität und Robustheit zusammengeführt. Dadurch soll erkennbar werden, ob ein möglicher Genauigkeitsvorteil mit höheren Kosten verbunden ist oder ob ein kleineres Modell unter den untersuchten Bedingungen ein günstigeres Verhältnis bietet. Eine nach Fehlerbedingungen und Anfragelast gegliederte Gegenüberstellung soll die Stärken und Nachteile der Ansätze sichtbar machen.

Der Beitrag zum Wissensstand liegt darin, die Robustheit eines vortrainierten MOMENT-Modells und zweier aufgabenspezifisch trainierter Modelle gemeinsam mit ihrem Cloud-Aufwand zu bewerten. Die bisher betrachteten Arbeiten untersuchen diese Aspekte überwiegend getrennt oder unter anderen Versuchsbedingungen. Nach Abschluss der Arbeit sollen für den gewählten Anwendungsfall vergleichbare Messwerte und dokumentierte Versuche vorliegen, auf deren Grundlage die Modellwahl begründet werden kann.

6 SCHLUSSFOLGERUNGEN UND AUSBLICK

Die Arbeit untersucht die datenbasierte Prognose der verbleibenden Nutzungsdauer von Maschinen und ist damit im Bereich der cloudbasierten Predictive Maintenance angesiedelt.

Fehlende oder veränderte Sensordaten können solche Prognosen beeinträchtigen, weshalb für die Modellwahl vergleichbare Erkenntnisse zur Robustheit und zum Aufwand des Cloud-Betriebs benötigt werden.

Dazu werden MOMENT-1-small, ein LSTM und ein TCN zunächst auf unveränderten und anschließend auf gleichartig beschädigten C-MAPSS-Testdaten ausgewertet. Messungen von Latenz, Ressourcenbedarf und Kosten ergänzen die Bewertung der Prognosefehler.

Die Eignung eines Modells soll anhand seiner Genauigkeit, seiner Reaktion auf Datenfehler und seines Betriebsaufwands beurteilt werden. Die Ergebnisse sollen eine Auswahlgrundlage für die drei untersuchten Ansätze schaffen, auch wenn sich dabei kein Vorteil von MOMENT gegenüber den Vergleichsmodellen zeigt.

Die nächsten Schritte umfassen die Umsetzung der Datenaufbereitung, das Training der Modelle und die anschließenden Fehlerexperimente sowie Messungen in der Cloud. Eine spätere Übertragung auf reale Anlagen oder andere TSFM muss die Grenzen der hier verwendeten Daten und Cloud-Umgebung berücksichtigen.

Literaturverzeichnis

Amin, A. A., Mubarak, A., Waseem, S., Alqarni, Z. A., & Manzoor, H. U. (2026). Remaining Useful Life (RUL) Prediction Methods for Machine Health Estimation and Fault Diagnosis: A Comprehensive Review of Latest Techniques and Future Prospects. *Engineering Reports*, *8*(4), e70699. https://doi.org/10.1002/eng2.70699

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the Language of Time Series. *Transactions on Machine Learning Research*. Verfügbar 18. Oktober 2026 unter https://openreview.net/forum?id=gerNCVqqtR

Berghout, T., & Benbouzid, M. (2022). A Systematic Guide for Predicting Remaining Useful Life with Machine Learning. *Electronics*, *11*(7), 1125. https://doi.org/10.3390/electronics11071125

Bergstra, J., & Bengio, Y. (2012). Random Search for Hyper-Parameter Optimization. *Journal of Machine Learning Research*, *13*(10), 281–305. Verfügbar 18. Oktober 2026 unter https://jmlr.org/papers/v13/bergstra12a.html

Bouthillier, X., Delaunay, P., Bronzi, M., Trofimov, A., Nichyporuk, B., Szeto, J., Sepah, N., Raff, E., Madan, K., Voleti, V., Kahou, S. E., Michalski, V., Serdyuk, D., Arbel, T., Pal, C., Varoquaux, G., & Vincent, P. (2021). Accounting for Variance in Machine Learning Benchmarks. *Proceedings of Machine Learning and Systems*, *3*, 747–769. Verfügbar 18. Oktober 2026 unter https://proceedings.mlsys.org/paper_files/paper/2021/hash/0184b0cd3cfb185989f858a1d9f5c1eb-Abstract.html

Cao, W., Wang, D., Li, J., Zhou, H., Li, L., & Li, Y. (2018). BRITS: Bidirectional Recurrent Imputation for Time Series. *Advances in Neural Information Processing Systems*, *31*. Verfügbar 18. Oktober 2026 unter https://proceedings.neurips.cc/paper_files/paper/2018/hash/734e6bfcd358e25ac1db0a4241b95651-Abstract.html

Che, Z., Purushotham, S., Cho, K., Sontag, D., & Liu, Y. (2018). Recurrent Neural Networks for Multivariate Time Series with Missing Values. *Scientific Reports*, *8*(1), 6085. https://doi.org/10.1038/s41598-018-24271-9

Das, A., Kong, W., Sen, R., & Zhou, Y. (2024). A Decoder-Only Foundation Model for Time-Series Forecasting. *Proceedings of the 41st International Conference on Machine Learning*, 10148–10167. Verfügbar 2. Oktober 2026 unter https://proceedings.mlr.press/v235/das24c.html

Dintén, R., & Zorrilla, M. (2025). Using Time Series Foundation Models for Few-Shot Remaining Useful Life Prediction of Aircraft Engines. *Computer Modeling in Engineering & Sciences*, *144*(1), 239–265. https://doi.org/10.32604/cmes.2025.065461

El-Ghoussani, A., De Vita, M., Naumann, R., & Belagiannis, V. (2026, 11. August). *Time-Series Foundation Model Embeddings for Remaining Useful Life Estimation*. arXiv: 2606.11990 [cs.LG]. https://doi.org/10.48550/arXiv.2606.11990

Goswami, M., Szafer, K., Choudhry, A., Cai, Y., Li, S., & Dubrawski, A. (2024). MOMENT: A Family of Open Time-Series Foundation Models. *Proceedings of the 41st International Conference on Machine Learning*, 16115–16152. Verfügbar 27. September 2026 unter https://proceedings.mlr.press/v235/goswami24a.html

Henderson, P., Hu, J., Romoff, J., Brunskill, E., Jurafsky, D., & Pineau, J. (2020). Towards the Systematic Reporting of the Energy and Carbon Footprints of Machine Learning. *Journal of Machine Learning Research*, *21*(248), 1–43. Verfügbar 18. Oktober 2026 unter https://jmlr.org/papers/v21/20-312.html

Hu, Y., Liu, S., Lu, H., & Zhang, H. (2019). Remaining Useful Life Model and Assessment of Mechanical Products: A Brief Review and a Note on the State Space Model Method. *Chinese Journal of Mechanical Engineering*, *32*(1), 15. https://doi.org/10.1186/s10033-019-0317-y

Ji, S., Han, X., Hou, Y., Song, Y., & Du, Q. (2020). Remaining Useful Life Prediction of Airplane Engine Based on PCA–BLSTM. *Sensors*, *20*(16), 4537. https://doi.org/10.3390/s20164537

Kapoor, S., & Narayanan, A. (2023). Leakage and the Reproducibility Crisis in Machine-Learning-Based Science. *Patterns*, *4*(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Leitner, P., & Cito, J. (2016). Patterns in the Chaos—A Study of Performance Variation and Predictability in Public IaaS Clouds. *ACM Trans. Internet Technol.*, *16*(3), 15:1–15:23. https://doi.org/10.1145/2885497

Li, X., Ding, Q., & Sun, J.-Q. (2018). Remaining Useful Life Estimation in Prognostics Using Deep Convolution Neural Networks. *Reliability Engineering & System Safety*, *172*, 1–11. https://doi.org/10.1016/j.ress.2017.11.021

Listou Ellefsen, A., Bjørlykhaug, E., Æsøy, V., Ushakov, S., & Zhang, H. (2019). Remaining Useful Life Predictions for Turbofan Engine Degradation Using Semi-Supervised Deep Architecture. *Reliability Engineering & System Safety*, *183*, 240–251. https://doi.org/10.1016/j.ress.2018.11.027

Saxena, A., Goebel, K., Simon, D., & Eklund, N. (2008). Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation. *2008 International Conference on Prognostics and Health Management*, 1–9. https://doi.org/10.1109/PHM.2008.4711414

Tang, D. (2026). A Deep Learning Framework for Remaining Useful Life Prediction of Turbofan Engines with Partial Sensor Failure. *PLOS ONE*, *21*(4), e0347312. https://doi.org/10.1371/journal.pone.0347312

Verbert, K., De Schutter, B., & Babuška, R. (2017). Timely Condition-Based Maintenance Planning for Multi-Component Systems. *Reliability Engineering & System Safety*, *159*, 310–321. https://doi.org/10.1016/j.ress.2016.10.032

Vogl, G. W., Weiss, B. A., & Helu, M. M. (2016). A Review of Diagnostic and Prognostic Capabilities and Best Practices for Manufacturing. *Journal of Intelligent Manufacturing*. https://doi.org/10.1007/s10845-016-1228-8

Wang, H., Peng, M., Xu, R., Ayodeji, A., & Xia, H. (2020). Remaining Useful Life Prediction Based on Improved Temporal Convolutional Network for Nuclear Power Plant Valves. *Frontiers in Energy Research*, *8*. https://doi.org/10.3389/fenrg.2020.584463

Wen, G.-H., & Chen, K.-Y. (2026, 24. August). *Do Time-Series Foundation Models Pay Off for Industrial Monitoring? A Cost-Aware Empirical Study*. arXiv: 2608.22968 [cs.LG]. https://doi.org/10.48550/arXiv.2608.22968

Wu, F., Wu, Q., Tan, Y., & Xu, X. (2024). Remaining Useful Life Prediction Based on Deep Learning: A Survey. *Sensors*, *24*(11), 3454. https://doi.org/10.3390/s24113454

Zhang, K., & Liu, R. (2023). LSTM-Based Multi-Task Method for Remaining Useful Life Prediction under Corrupted Sensor Data. *Machines*, *11*(3), 341. https://doi.org/10.3390/machines11030341

Zonta, T., da Costa, C. A., da Rosa Righi, R., de Lima, M. J., da Trindade, E. S., & Li, G. P. (2020). Predictive Maintenance in the Industry 4.0: A Systematic Literature Review. *Computers & Industrial Engineering*, *150*, 106889. https://doi.org/10.1016/j.cie.2020.106889